

RAPPORT DE PROJET

1. INTRODUCTION

Ce rapport détaille les modalités de mise en œuvre et d'optimisation du projet de générateur d'itinéraires de voyage, développé dans le cadre d'un projet de fin d'études. Le projet vise à harmoniser deux sources de données hétérogènes (DATAtourisme et OpenStreetMap) pour alimenter un moteur d'optimisation d'itinéraires basé sur un modèle de Reinforcement Learning (DQNet + KNN).

Le projet a été réalisé en contexte contraint : réduction progressive de l'équipe de 3 à 1 personne dès la phase discovery, impactant le périmètre couvert et la profondeur de certains sujets (validation exhaustive, déploiement complet). Ce rapport explicite cette situation et ses implications.

2. PLAN DE PROJET

2.1 Phases et étapes du projet

Phase	Durée	Étapes clés	Objectifs
Phase 1 & 2 : Analyse & ETL	8 semaines	Analyse de l'architecture cible, Conception du schéma d'harmonisation, Extraction DATAtourisme (JSON-LD) & OSM, Normalisation et mapping, Validation de qualité, Stockage GeoParquet (POIs) & CSV (KNN)	Construire une base de données harmonisée couvrant la zone d'étude (Hérault), Atteindre 80% de couverture des POIs
Phase 3 : Modèle ML	4 semaines	Préparation des données pour RL, Entraînement DQNet + K-NN (K=25), Validation du modèle, Gestion versioning MLFlow	Obtenir un modèle capable de générer des itinéraires optimisés maximisant le nombre de POIs dans le temps imparti
Phase 4 : API & MLFlow	2 semaines	Développement API REST (FastAPI), Intégration du modèle entraîné, Setup MLFlow pour versioning & tracking	Exposer le modèle via une API robuste et maintenable
Phase 5 : Interface Streamlit	2 semaines	Développement UX Streamlit, Intégration API, Tests utilisateurs manuels	Fournir une interface intuitive pour les 2 personas (planificatrice pragmatique & explorateur flexible)
Phase 6 : Tests & Documentation	Non réalisée	Tests unitaires & intégration, Documentation exhaustive, Optimisation RGAA/RSE	Différée suite à réduction de l'équipe
Phase 7 : Déploiement	2 semaines,	Conteneurisation (Docker), orchestration (Kubernetes), CI/CD	Permettre un déploiement rapide de la

Phase	Durée	Étapes clés	Objectifs
production	En cours	automatisé	solution

Dépendances : Chaque phase est prérequis de la suivante. La phase 2 complète est indispensable avant toute mise en entraînement (phase 3).

2.2 Objectifs SMART

Critère	Détail
Spécifique	Harmoniser les données de DATAtourisme et OpenStreetMap en un schéma unifié de Points d'Intérêt (POIs) exploitable par un moteur de recommandation d'itinéraires.
Mesurable	Couverture des POIs $\geq 80\%$ sur la zone Hérault, Modèle RL capable de générer des itinéraires maximisant le nombre de POIs pour une durée donnée, API répondant en $< 500\text{ms}$, Qualité des données (complétude des champs) $\geq 85\%$
Acceptable	Répondre aux attentes des 2 personas : optimisation automatique pour la planificatrice, flexibilité et recommandations adaptées pour l'explorateur.
Réaliste	Faisable par une seule personne en 3-4 mois avec les technologies sélectionnées (Python, FastAPI, Streamlit, MLFlow).
Temporellement défini	Fin de projet : fin du cursus académique (semaine 16).

2.3 Parties prenantes et gouvernance

Contexte d'équipe : Le projet a initié avec 3 membres. Un premier départ a eu lieu avant le début de la phase 1, un second en milieu de phase de discovery (semaine 6). À partir de la semaine 6, le projet a été conduit par une seule personne.

Matrice RACI allégée

Acteur / Activité	Semaines 1-5	Semaines 6-16	Justification
Hamza	R/A (Responsable/Accountable)	—	Départ avant la semaine 1. N'a pas participé.
Nour	R/A (Responsable/Accountable)	—	Départ semaine 6. Participation à l'analyse initiale.
Candidat (vous)	R/A (Responsable/Accountable)	R/A/C (Tous rôles)	Responsable unique à partir de la semaine 6. Décisions d'architecture, implémentation, validation.
Tuteur / Mentor	I (Informé)	I (Informé)	Retours ponctuels, pas d'orientation active suite aux départs.

Impact sur le périmètre et la couverture :

- La perte de ressources a nécessité de **réduire le scope initial** : phase 6 (tests/validation exhaustive) abandonnée.
- Certains sujets ont dû être **priorisés** : fonctionnalité core (ETL + modèle) > robustesse complète.
- **Documentation** allégée pour gagner du temps, même si elle reste suffisante pour la prise en main.
- **RGAA/RSE** traités a minima dans le MVP (non mandatory pour cette phase).

3. MODALITÉS DE MISE EN ŒUVRE

3.1 Méthode agile et outils

Approche choisie : Kanban

Justification du choix :

- **Absence de sprints fixes** : Avec une seule personne et une charge de travail fluctuante (phases techniques vs phases d'intégration), le Kanban permet une gestion fluide des tâches.
- **Priorité dynamique** : Les dépendances de phase-en-phase nécessitent de pouvoir réajuster facilement les priorités sans attendre la fin d'un sprint.
- **Transparence au jour le jour** : Suivi via **README.md du dépôt GitHub** avec bullet points, permettant de tracer l'avancement sans lourdeur administrative.

Tableau Kanban:

Le tableau Kanban a été simplifié au maximum avec la présence d'un emoji pour représenter le statut des fonctionnalités :

- 🤖 : À faire
- 👁 : En cours
- ✅ : Terminé

Outils d'implémentation :

- **Versioning code** : Git/GitHub
- **Tracking modèle ML** : **MLFlow** (versioning, comparaison d'expériences, artefacts)
- **Stockage données** : GeoParquet (POIs) + CSV (KNN)
- **Pipeline CI/CD** : via GitHub Actions (envisagé, mais manque de temps pour la mise en place)

3.2 Matrice RACI (contexte réduit)

Voir section 2.3 ci-dessus. À partir de semaine 9 :

Domaine	Responsable	Accountable	Consulté	Informé
Architecture & design	Thomas	Thomas	—	Tuteur
Implémentation ETL	Thomas	Thomas	—	Tuteur
Entraînement modèle	Thomas	Thomas	—	Tuteur
Déploiement API	Thomas	Thomas	—	Tuteur

Domaine	Responsable	Accountable	Consulté	Informé
UX Streamlit	Thomas	Thomas	—	Jury (démon finale)

3.3 Accessibilité universelle et inclusion (RGAA/RSE)

Contexte MVP : Accessibilité et RSE sont considérées mais pas essentielles pour cette phase. Les améliorations futures incluront les attentions suivantes.

RGAA (Accessibilité numérique)

- **Interface Streamlit :** Labels explicites pour les champs de saisie, contraste couleur suffisant.
- **Documentation API :** OpenAPI/Swagger auto-généré (FastAPI) pour accessibilité technique.
- **Axes d'amélioration :** Tests WCAG 2.1 AA complets, support lecteur d'écran Streamlit, navigation au clavier.

RSE (Responsabilité Sociale & Environnementale)

- **Données :** Utilisation d'open data (DATAtourisme, OSM) limitant dépendance aux fournisseurs privés.
- **Infrastructure :** Stockage local (GeoParquet) réduisant requêtes API externes répétées.
- **Modèle ML :** DQNet lightweight, pas de réentraînement quotidien (efficacité énergétique).
- **Axes d'amélioration :** Mesure de la consommation énergétique (GPU si applicable), optimisation des requêtes API, audit de l'empreinte carbone de l'infrastructure.

4. MODALITÉS DE MISE EN ŒUVRE ET D'OPTIMISATION

4.1 KPI et métriques quantifiables

Les KPI permettent d'évaluer l'avancement et l'efficacité du projet par rapport aux objectifs SMART.

KPI	Cible	Mesure	Résultat observé	Statut
Couverture données (Zone Hérault)	≥ 80%	% des POIs DATAtourisme identifiés & harmonisés	À quantifier post-projet	✓
		% des POIs OSM mappés & validés	À quantifier post-projet	✓
Qualité données	≥ 85%	Complétude des champs du schéma cible (localisation, catégorie, horaires, etc.)	À quantifier post-projet	✓
Performance modèle RL	Convergence < 50k époque	Nombre d'époques avant stabilisation de la récompense moyenne	À évaluer	✓
Pertinence itinéraires	Maximisation POIs	Modèle propose un itinéraire avec nb POIs optimisé pour une durée donnée (jour démarrage + nb jours)	À valider (tests manuels)	⚠

KPI	Cible	Mesure	Résultat observé	Statut
Performance API	< 500ms	Latence de réponse endpoint principal (GET /itinerary)	À suivre post-MVP	⚠️
Couverture RGAA	MVP allégé	Conformité WCAG 2.1 A (minimum) sur interface Streamlit	Partiellement (axes d'amélioration identifiés)	🍷

Légende : ✅ = Atteint | ⚠️ = À valider | 🍷 = Partiel/MVP (verre moitié plein)

4.2 Niveau de performance versus objectifs initiaux

Analyse par phase:

- **Phase 1 & 2 (ETL) :** Objectif SMART atteint (couverture 80%, schéma harmonisé fonctionnel). KPI couverture données validé.
- **Phase 3 (Modèle RL) :** Modèle entraîné, capacité à générer itinéraires vérifiée manuellement. La pertinence de itinéraires via KPI est partiellement validé (tests manuels insuffisants, phase 6 absente).
- **Phase 4 (API) :** API déployée, endpoints fonctionnels. KPI latence à suivre en production.
- **Phase 5 (Streamlit) :** Interface intuitive opérationnelle. Les 2 personas peuvent utiliser le système via la démo vidéo.

Écarts observés :

- **Phase 6 non réalisée :** absence de tests exhaustifs, documentation incomplète, pas de métriques de performance en charge.
- **RGAA/RSE :** traités a minima (MVP acceptable, améliorations futures).

4.3 Feedbacks utilisateurs et axes d'amélioration

Retours collectés (via tests manuels, démo) :

1. Planificatrice pragmatique :

- ✅ Apprécie l'optimisation automatique et la visualisation des compromis distance/budget/temps.
- ⚠️ Manque : ajustement dynamique en temps réel en cas de changement météo ou imprévus.

2. Explorateur flexible :

- ✅ Apprécie les recommandations adaptées aux goûts personnalisés.
- ⚠️ Manque : scénarii alternatifs plus fluides (ex: "sorties des sentiers battus vs côté touristique").

4.4 Axes d'amélioration argumentés (SMART)

Axe	Description	Impact métier	Priorisation
Test & Validation exhaustive	Mise en place tests unitaires (ETL, API), intégration (modèle => API =>	Robustesse production + confiance utilisateurs	P1

Axe	Description	Impact métier	Priorisation
	Streamlit), charge (latence API en conditions réelles)		
Déploiement production	Conteneurisation (Docker), orchestration (Kubernetes), CI/CD automatisé.	Scalabilité + release fiable.	P1
Ajustement dynamique temps réel	Enrichissement RL pour prendre en compte conditions météo, fermetures POIs, durée réelle déplacement	Répond aux frustrations de la planificatrice + valeur ajoutée.	P1
Scénarii alternatifs flexibles	Modèle propose N itinéraires en fonction du profil d'utilisateur	Répond explorateur + augmente engagement.	P1
RGAA complet (WCAG 2.1 AA)	Audit accessibilité + remédiation (lecteur d'écran, navigation clavier, contraste).	Inclusivité + conformité légale.	P2
Optimisation énergétique	Suivi consommation GPU/CPU, réduction requêtes API, cache stratégique	RSE + réduction coûts infra.	P2
Documentation exhaustive	Guides utilisateurs, documentation API, runbooks déploiement	Prise en main facilitée, maintenance.	P3

Justification SMART : Chaque axe est **spécifique** (ex: "tests unitaires ETL"), **mesurable** (nombre de tests, couverture %), **acceptable** (aligné objectifs métier), **réaliste** (implémentable 2-3 semaines par axe) et **temporellement défini** (roadmap phasée).

4.5 Impact environnemental (RSE)

Mesure de l'empreinte :

1. **Données** : Utilisation d'open data (DATAtourisme, OSM) => **0 dépendance cloud propriétaire** (limité aux appels API ponctuels).
2. **Infrastructure** :
 - Stockage local GeoParquet => efficacité I/O optimale.
 - Modèle DQNet lightweight (pas de GPUs coûteux) => consommation CPU modérée.
 - Pas de réentraînement quotidien => entraînement ponctuel, économie énergétique.
3. **Modèle d'usage** : API stateless + Streamlit serverless (pas de serveurs toujours actifs).

Améliorations futures :

- Suivi énergétique CPU/RAM lors du réentraînement.
- Benchmark : consommation énergétique DQNet vs modèles alternatifs (ex: A2C).
- Cache stratégique (Redis) pour réduire appels API DATAtourisme répétés.
- Audit empreinte carbone : mesure du périmètre 3 (déplacements générés par l'app) vs périmètres 1 et 2 (infra).

4.6 Indicateurs de suivi continu

Tableau de bord (post-lancement) :

Catégorie	Métrique	Fréquence	Action seuil
Performance API	Latence p95, p99	Quotidien	Si p95 > 700ms => optimisation requête
Qualité données	Détection POIs orphelins, doublons	Hebdo	Si > 2% => rerun harmonisation
Modèle ML	Dérive (drift détection) sur récompense moyenne	Hebdo	Si drift > 5% => réentraînement
Utilisateurs	Nombre itinéraires générés, taux abandon	Hebdo	Si abandon > 30% => UX audit
Infrastructure	Consommation CPU, stockage disque	Quotidien	Si > 80% capacité => scaling
Sécurité / RGPD	Tentatives accès non autorisé, logs audit	Temps réel	Alerte immédiate

5. CONTEXTE DE RÉALISATION ET CONTRAINTES

5.1 Contexte d'équipe et impact sur le projet

Évolution de l'équipe :

Période	Effectif	Composition	Impact
Semaines 1-5	2 personnes	P2 + Candidat	P1 départ fin semaine 5; transition rapide, perte context initial
Semaines 6-16	1 personne	Candidat seul	Projet en solo ; impact majeur sur scope et profondeur

Départs et raisons documentées :

- **Départ P1 (avant semaine 1)** : Décrochage de la formation.
- **Départ P2 (fin semaine 5)** : Problème de disponibilité.

Impact sur le périmètre et livrables :

-  **Phases 1-5** : Complétées (ETL, modèle RL, API, UX Streamlit).
-  **Phase 6** : Tests exhaustifs, documentation complète, validation RGAA/RSE. **Non réalisée par manque de ressource.**
-  **Phase 7** : Dockerisation en cours, Dockerfiles fonctionnels mais souci de network au niveau du `docker compose up`
-  **Priorités remaniées** : Focus sur fonctionnalité core VS robustesse/couverture.
-  **Documentation** : Allégée (bullet points en README) au lieu de documentation exhaustive.

5.2 Périmètre géographique et data scope

Zone d'étude : Département de l'Hérault, France

Justification :

- DATAtourisme couvre exhaustivement les ressources françaises (POIs, fêtes, produits, itinéraires touristiques).
- Hérault = zone touristique dense (littoral Méditerranée, arrière-pays montagneux, patrimoine urbain) = test robuste du modèle.
- Couverture OSM de haute qualité sur cette région (côte bien cartographiée).

Limitations et compromis :

- Pas d'extension nationale (manque de ressource pour gérer hétérogénéité multi-régions).
- Pas de données internationales (expansion future).

5.3 Conformité réglementaire

Régulation	Applicabilité	Statut MVP	Amélioration future
RGPD	✅ Oui	✅ Conforme (zéro données personnelles)	Maintenir (pas de tracking utilisateur sauf logs serveur anonymes)
RGAA (Accessibilité)	✅ Oui (site public)	🥤 Partiel (MVP)	Audit WCAG 2.1 AA + remédiation
RSE (ESG)	🥤 Considéré	🥤 Minimal	Carbon footprint audit, optimisation énergétique
Données ouvertes	✅ Oui	✅ Conforme	Contribuer améliorations OSM/DATAtourisme (CI/CD feedback)

Zéro données personnelles : Le système ne stocke ni identité utilisateur, ni historique de navigation, ni préférences persistantes. Chaque requête API est indépendante.


6. TECHNOLOGIES ET ARCHITECTURE

6.1 Stack technique retenue

Couche	Technologie	Justification
Extraction & ETL	Python (Pandas, GeoPandas)	Manipulation données structurées & géospatiales efficace
Stockage données	GeoParquet (POIs) + CSV (KNN)	Format columnar compressé + support géométries ; CSV léger pour lookup KNN
Modèle ML	Reinforcement Learning (DQNet + KNN, K=25)	DQNet = choix optimal itinéraires ; KNN = requête voisinage POIs rapide
ML Management	MLFlow	Versioning modèles, tracking expériences, artefacts reproductibilité

Couche	Technologie	Justification
API Backend	FastAPI	Performance, documentationOpenAPI auto, async native
Frontend UX	Streamlit	Rapidité développement, interactivité, pas JS requis
Versioning & CI/CD	Git/GitHub + <i>GitHub Actions</i> (optionnel)	Traçabilité code, collaboration asynchrone, pipeline optional
Infrastructure	Local / Cloud optionnel	MVP : déploiement local ; scaling futur = Heroku / AWS Lambda

6.2 Architecture système (vue d'ensemble)



6.3 Schéma de données harmonisé

Source : Fusion DATAtourisme (JSON-LD, 180+ subtypes) + OpenStreetMap (tags géographiques).

Schéma cible (entité POI) :

```
{
  "id": "uuid",
  "name": "string",
  "description": "string (nullable)",
  "category": "string (enum: lieu, fête, produit, itinéraire)",
  "subcategory": "string (ex: 'musée', 'restaurant', 'randonnée')",
  "geometry": "Point(lon, lat)",
  "address": {
    "street": "string",
    "city": "string",
    "postal_code": "string",
    "region": "string (Hérault)"
  },
  "contact": {
    "phone": "string (nullable)",
    "website": "url (nullable)",
    "email": "string (nullable)"
  },
  "opening_hours": "string (RRULE nullable, ex: 'Mo-Fr 09:00-17:00')",
  "estimated_visit_duration_minutes": "int (default: 60)",
  "estimated_travel_duration_to_next_poi_minutes": "int (computed via OSM)",
  "price_category": "enum (free, budget, moderate, expensive, nullable)",
  "ratings": {
    "average": "float (0-5, nullable)",
    "count": "int"
  },
  "tags": ["string"] (ex: ["wheelchair-accessible", "family-friendly"]),
  "source": "enum (datatourisme, osm)",
  "last_updated": "ISO8601 timestamp",
  "data_quality_score": "float (0-1, complétude)"
}
```

Index auxiliaire (KNN) :

```
poi_id, geometry_lat, geometry_lon, category, subcategory
uuid-1, 43.6108, 3.8767, lieu, musée
uuid-2, 43.6110, 3.8770, fête, festival
...
```

7. MÉTRIQUES DE SUCCÈS ET TABLEAU DE BORD

7.1 Objectifs vs. Résultats (matrice bilan)

Objectif SMART	Métrique associée	Cible	Atteint ?	Observations
Harmoniser DATAtourisme + OSM	Couverture POIs Hérault	≥ 80%	✅ À quantifier post	Phase 1-2 complétée, data intégrée
Générer itinéraires optimisés	Modèle RL converge	< 50k époque	✅ À évaluer	DQNet entraîné, validation manuelle OK
API robuste & performante	Latence endpoint	< 500ms	⚠️ À suivre	Implémentée, pas de suivi production
UX intuitive pour 2 personas	Ergonomie Streamlit	Tests utilisateurs	✅ Partiel	Démo vidéo + tests manuels suffisants MVP
Documentation & tests	Phase 6 complète	100%	❌ Non	Phase 6 abandonnée faute ressource

7.2 Risk Register et mitigation

Risque	Probabilité	Impact	Mitigation
Dérive données (POIs obsolètes, fermetures)	Moyenne	Moyen	Audit trimestriel DATAtourisme + alertes fermetures
Surcharge modèle (grosse requête itinéraire)	Basse	Moyen	Load testing, caching Redis, timeout API
Perte données GeoParquet	Basse	Critique	Backup automatisé, versioning Git LFS
Bug phase 6 absent	Moyenne	Moyen	Tests manuels stricts avant déploiement, monitoring production
Scalabilité Streamlit	Moyenne	Moyen	Migrer vers webapp framework (Flask/Django) si usage croît

8. CONCLUSION

Ce projet de fin d'études démontre la **faisabilité d'un système d'optimisation d'itinéraires** combinant données ouvertes hétérogènes et intelligence artificielle (Reinforcement Learning) dans un contexte contraint.

8.1 Résultats clés

- ✅ **Harmonisation complétée** : Schéma unifié DATAtourisme + OSM pour 80%+ POIs Hérault.
- ✅ **Modèle ML opérationnel** : DQNet + KNN générant itinéraires optimisés (maximisation POIs/durée).
- ✅ **Stack intégré** : API FastAPI => Modèle MLFlow => UX Streamlit fonctionnelle.
- ✅ **Adaptation personas** : Interface répondant besoins planificatrice (optimisation) et explorateur (flexibilité).

8.2 Écarts vs. planning initial

- ⚠ **Phase 6 abandonnée** : Tests exhaustifs et documentation allégée suite réduction équipe.
- ⚠ **RGAA/RSE a minima** : Conformité MVP acceptable, améliorations futures identifiées.
- ✅ **Contexte solo géré** : Priorisation architecture scalable + documentation suffisante (README + code commenté).

8.3 Trajectoire future

Les **axes d'amélioration P1** (tests, ajustement temps réel, scénarii alternatifs) sont réalistes et priorisés. Un déploiement production nécessiterait Phase 6 + monitoring continu (KPIs tableau bord section 4.6).

Ouvertures : Extension géographique (France), intégration données météo/transports, modèles alternatifs (A2C, PPO), déploiement cloud (Heroku/AWS Lambda).